



Contents lists available at [ScienceDirect](#)

# Neurocomputing

journal homepage: [www.elsevier.com/locate/neucom](http://www.elsevier.com/locate/neucom)



## Extreme learning machine ensemble model for time series forecasting boosted by PSO: Application to an electric consumption problem

Mikel Larrea <sup>a,\*</sup>, Alain Porto <sup>b</sup>, Eloy Irigoyen <sup>a</sup>, Antonio Javier Barragán <sup>c</sup>, José Manuel Andújar <sup>c</sup>

<sup>a</sup> UPV/EHU, Barrio Sarriena s/n, 48940 Leioa, Spain

<sup>b</sup> IDEKO, Arriaga Industrialdea 2, 20870 Elgoibar, Spain

<sup>c</sup> UHU, Avda. de las Fuerzas Armadas s/n, 21007 Huelva, Spain

**Grupo:**  
**Filipe Coelho de Lima Duarte (fcld)**  
**José Flávio Vieira Melo (jfvvm)**

---

# Introdução e motivação do trabalho



# Introdução

- Previsão de séries temporais
- ELM
- Ensemble model
- Particle Swarm Optimization (PSO)
- Combinar modelos ELM com PSO é superior à combinação pela média?

---

# Método proposto



## Método proposto por Larrea et al. (2020)

- Normalização gaussiana (standard scale)
- Geração do pool de ELM (avaliação de diversas topologias)
- Combinação por ranking de forma incremental
- Normalização dos pesos (garantia das restrições)
- PSO para otimizar os pesos da combinação



## Combinação das previsões

A previsão final gerada pelo *Ensemble* otimizado pelo PSO está representada na equação 5

$$\hat{Y}_{ens}(X_{M \times 1}) = \sum_{j=1}^k \alpha_j \hat{Y}_j(X_{M \times 1}) \quad (5)$$



## Restrições e métrica de aptidão

- Restrições e normalização dos pesos

$$\sum_{j=1}^k \alpha_j = 1.$$

$$\mathbf{A}_{normalizado} = \frac{e^{\mathbf{A}}}{\sum_{j=1}^k e^{\alpha_j}}$$

- Métrica de erro (aptidão PSO)

$$\begin{aligned} NMSE(F) &= \frac{\sum_{h \in \mathcal{T}} (\text{observação}_h - \text{previsão}_h)^2}{\sum_{h \in \mathcal{T}} (\text{observação}_h - \text{média}_{\mathcal{T}})^2} \\ &\approx \frac{1}{\hat{\sigma}_{\mathcal{T}}^2} \frac{1}{F} \sum_{h \in \mathcal{T}} (x_h - \hat{x}_h)^2 \end{aligned}$$

---

# Experimentos





# Experimentos

- Experimento I
- Experimento II
- Métrica de avaliação dos resultados: Root mean squared error (RMSE)

$$RMSE = \sqrt{\frac{1}{F} \sum_{h=1}^F (\hat{Y}_h - Y_h)^2}$$

---

# Experimento I: Santa Fé laser strength forecasting



## Dados e avaliação dos resultados

- Qtd. de observações: 1100:
  - das quais, as primeiras 1000 observações para treinamento
  - 100 observações restantes para teste
- Topologia e processo de treinamento → gerou-se 100 modelos com topologias:
  - Qtd. dados entrada (valores passados da série): [10, 20, 30, 40, 50, 100, 150]
  - Qtd. neurônios na camada escondida: [20, 50, 100, 110, 150, 160, 170]
  - Processo de otimização com PSO incremental (do melhor modelo até o pior) para cada topologia
- Após, selecionamos 20% do conjunto de treinamento para validação com o PSO.
- Processo de previsão para os dados de teste (previsão e incorporação à série)
- Avaliação de *overfitting*: taxa média da diferença do RMSE entre treinamento e teste:
  - Sem validação: 94,23%
  - Com validação: 57,69%

## Série temporal e Autocorrelação




Fig. 3. Série Santa Fé




Fig. 4. ACF da série Santa Fé

## Previsão e Melhores modelos




Fig. 9. Valores observados para o conjunto de teste e previsões pelo melhor modelo ELM, PSO, Média e Mediana

TABLE II  
MELHORES MODELOS ELM EM RELAÇÃO AO RMSE

n_input	n_hidden	RMSE
30	150	1.275
40	20	1.300
30	160	1.309
20	20	1.356
20	150	1.356




Fig. 5. RMSE em função das quantidades de neurônios na camada de entrada e na camada escondida para o conjunto de treinamento




Fig. 7. RMSE em função das quantidades de neurônios na camada de entrada e na camada escondida para o conjunto de teste




Fig. 6. RMSE em função das quantidades de neurônios na camada de entrada e na camada escondida para o conjunto de validação

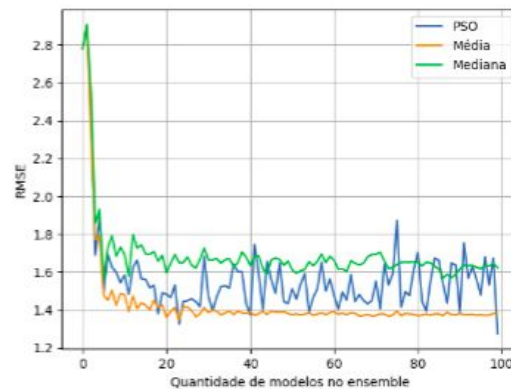


Fig. 8. RMSE em função da quantidade de ELM do pool com melhor desempenho

---

# Experimento II: consumo de energia espanhola

# Série temporal e Autocorrelação

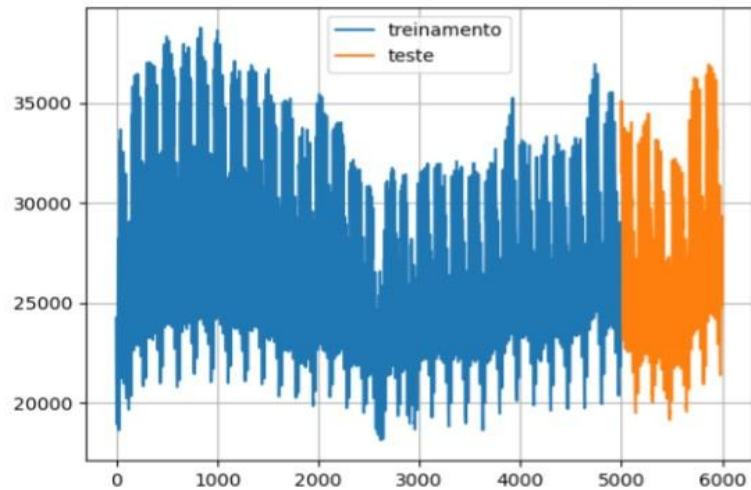


Fig. 10. Série Consumo de energia espanhola




Fig. 11. ACF da série Consumo de energia espanhola





## Problemas com execução

- Observações 26304
- Busca por topologias [10,20...,300] - inviável.
- Seleção das melhores topologias ELM apontadas no artigo citado.
- Tempo de execução foi um total de 10 dias, sendo 3 para treino e 7 para teste - Amostragem total.
- Tempo de execução foi um total de 1,2 dias, sendo 1 dias para treino e 6 horas para teste - amostragem customizada.



## Dados e avaliação dos resultados

- 5000 observações para treinamento
- 1000 obs. para teste
- Topologia e processo de treinamento → gerou-se 100 modelos com topologias:
  - Qtd. dados entrada (valores passados da série): [ 30, 40, 50, 60, 90]
  - Qtd. neurônios na camada escondida: [100, 140, 150, 160]
  - Processo de otimização com PSO incremental (do melhor modelo até o pior) para cada topologia
- Após, selecionamos 20% do conjunto de treinamento para validação com o PSO.
- Processo de previsão para os dados de teste (previsão e incorporação à série)
- Avaliação de *overfitting*: taxa média da diferença do RMSE entre treinamento e teste:
  - Sem validação: 452%
  - Com validação: -9%

## Previsão e Melhores modelos




TABLE III  
MELHORES MODELOS ELM EM RELAÇÃO AO RMSE - CONSUMO DE  
ENERGIA ESPANHOLA

n_input	n_hidden	RMSE
90	140	1.897
90	160	2.159
90	100	2.232
90	150	2.545
60	160	2.882




Fig. 12. RMSE em função das quantidades de neurônios na camada de entrada e na camada escondida para o conjunto de treinamento - Base Consumo de energia espanhola

RMSE vs Neurônios camada escondida vs Neurônios camada de entrada


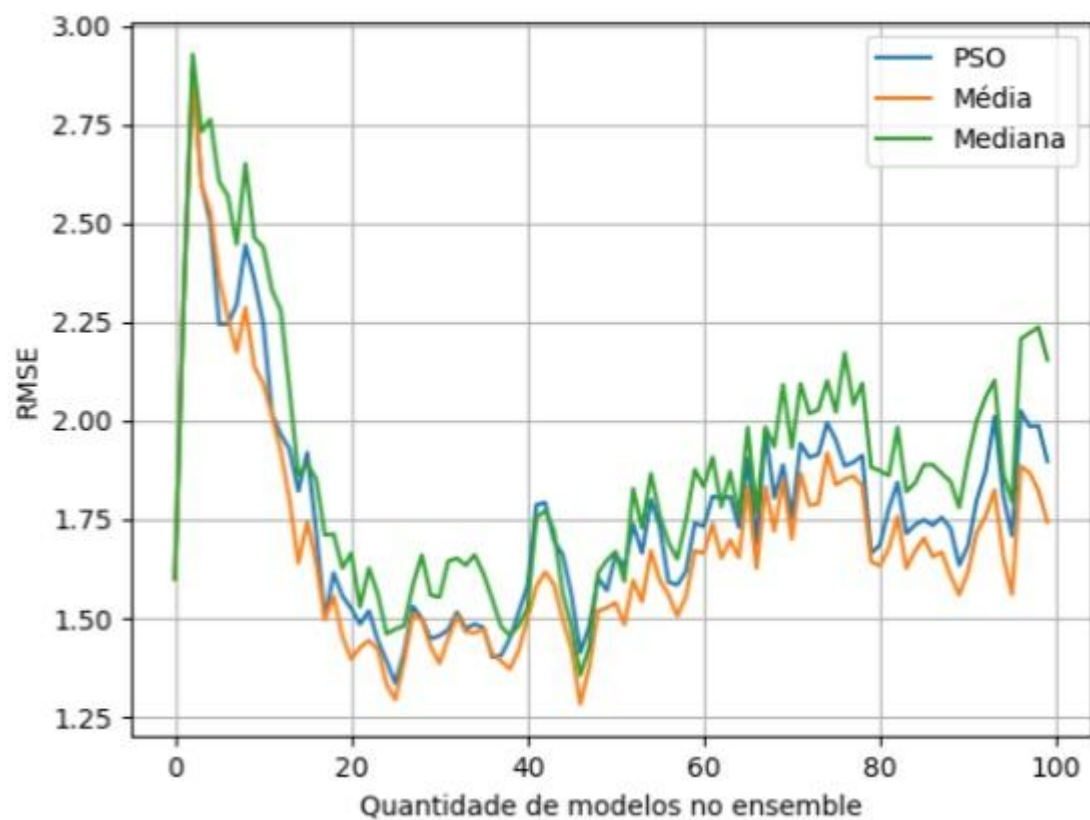


Fig. 13. RMSE em função das quantidades de neurônios na camada de entrada e na camada escondida para o conjunto de teste - Base Consumo de energia espanhola



---

# Conclusão



## Achados, crítica e sugestões

- Os resultados observados para ambos experimentos demonstraram que a combinação pelo PSO não foi superior à combinação pela média.
- Redes ELM são modelos fortes (Experimento II).
- O aumento da quantidade de regressores não melhorou mais do que 20 modelos

### Críticas

- Poderia combinar as topologias no Ensemble
- Testar modelo base mais fraco (ex.: regressão linear)
- Faltou realizar validação cruzada ao longo do tempo.
- Modelo CQSO para ambientes dinâmicos (série temporal)



## Referências

- [1] M. Larrea, A. Porto, E. Irigoyen, A. J. Barragán, and J. M. Andújar, "Extreme learning machine ensemble model for time series forecasting boosted by PSO: Application to an electric consumption problem," *Neurocomputing*, nov 2020.
- [2] G.-B. Huang, Q.-Y. Zhu, and C.-K. Siew, "Extreme learning machine: a new learning scheme of feedforward neural networks," in *2004 IEEE International Joint Conference on Neural Networks (IEEE Cat. No.04CH37541)*. IEEE.
- [3] J. Mendes-Moreira, C. Soares, A. M. Jorge, and J. F. D. Sousa, "Ensemble approaches for regression: A survey," *Acm computing surveys (csur)*, vol. 45, no. 1, pp. 1–40, 2012.
- [4] N. García-Pedrajas, C. Hervás-Martínez, and D. Ortiz-Boyer, "Cooperative coevolution of artificial neural network ensembles for pattern classification," *IEEE transactions on evolutionary computation*, vol. 9, no. 3, pp. 271–302, 2005.
- [5] J. Kennedy and R. Eberhart, "Particle swarm optimization," in *Proceedings of ICNN'95 - International Conference on Neural Networks*. IEEE.
- [6] Y. Zhang, S. Wang, and J. G, "A comprehensive survey on particle swarm optimization algorithm and its application," *Mathematical Problems in Engineering*, vol. 2015, p. 38, 2015.
- [7] Y. Liu, B. He, D. Dong, Y. Shen, T. Yan, R. Nian, and A. Lendasse, "Particle swarm optimization based selective ensemble of online sequential extreme learning machine," *Mathematical Problems in Engineering*, vol. 2015, 2015.
- [8] A. Porto, E. Irigoyen, and M. Larrea, "A pso boosted ensemble of extreme learning machines for time series forecasting," in *The 13th International Conference on Soft Computing Models in Industrial and Environmental Applications*. Springer, 2018, pp. 324–333.
- [9] S. A. Abdulkarim and A. P. Engelbrecht, "Time series forecasting with feedforward neural networks trained using particle swarm optimizers for dynamic environments," *Neural Computing and Applications*, pp. 1–17, 2020.





# Obrigado!

Contato:

Filipe C L Duarte: [fcld@cin.ufpe.br](mailto:fcld@cin.ufpe.br)

José Flávio V M: [jfvm@cin.ufpe.br](mailto:jfvm@cin.ufpe.br)